


MACHINE LEARNING CANVAS · PROPUESTA DE PROYECTO

Predicción de Churn de Clientes

Un modelo predictivo de riesgo de abandono para anticipar bajas y habilitar acciones preventivas de retención.

Presentado por: Dankiewicz Nicolas – Zaffar Camila – Sánchez Maria Clara

El canvas completo, de un vistazo



Estructura de la presentación

01

Contexto y propuesta de valor

Por qué este proyecto importa para el negocio

02

Tarea de predicción

Qué predice el modelo y cómo se define el problema

03

De la predicción a la acción

Decisiones, features y fuentes de datos

04

Construcción y despliegue

Entrenamiento, generación de predicciones y monitoreo

05

Impacto esperado y próximos pasos

Criterios de éxito y hoja de ruta

Por qué este proyecto



El problema de negocio

Un nivel creciente de churn erosiona los ingresos recurrentes, y hoy la organización **desconoce las causas** detrás del abandono de clientes.

Valor entregado

Información anticipada sobre el comportamiento de las cuentas y la posibilidad de ejecutar acciones preventivas antes de la baja.



Objetivo de negocio

Reducir el churn

Mediante intervenciones oportunas y focalizadas sobre las cuentas de mayor riesgo.



Usuario final

Equipo de Customer Experience

Consumirá las predicciones para decidir qué cuentas priorizar.

Qué predice el modelo



Problema de **clasificación supervisada**, desbalanceado, que estima el nivel de riesgo de abandono de cada cuenta.



Riesgo Alto

categoría de salida



Riesgo Medio

categoría de salida



Riesgo Bajo

categoría de salida



No Churn

categoría de salida

Definición de la categoría

Categoría = Probabilidad de churn × Revenue mensual de la cuenta

Umbral de riesgo definidos en conjunto con el equipo de negocio.

De la predicción a la acción

El objetivo no es solo anticipar la baja, sino accionar antes de que ocurra: ofrecer descuentos u otras intervenciones según la categoría de riesgo asignada.



01

Modelo asigna categoría

Riesgo alto / medio / bajo / no churn, por cuenta



02

Dashboard entrega propuesta

El equipo de CX accede por ID de cuenta a la categoría y a una acción sugerida



03

Acción ejecutada sin fricción

No human in the loop: la propuesta puede tomarse sin consultar

Fuentes de datos

Fuentes internas de la empresa, con datos históricos disponibles desde 2024 hasta julio del presente año. No se utilizan datos sensibles.



Data Warehouse

Extractos históricos entregados
en formato CSV



Sistemas OLTP

Accedidos en tiempo real
mediante API



HubSpot

Datos de interacción comercial y
marketing



Zendesk

Historial de contacto y soporte
al cliente

Clave de integración: un ID de cuenta único ("ID Fudo") presente en todos los sistemas permite cruzar la información entre fuentes.

Recolección y actualización de datos



Entrenamiento

Snapshot mensual de la información de cada cuenta, sobre datos históricos.



Reentrenamiento

Proceso definido para incorporar datos nuevos y mantener el modelo actualizado.



Etiquetado

Automático, mediante un algoritmo de etiquetado — sin intervención manual.



Limpieza

Se excluyen cuentas con estacionalidad de uso (altas y bajas recurrentes) que distorsionan la señal.

Variables del modelo



Disponibles hoy

Las features principales ya se encuentran extraídas en la tabla de estadística de cada cuenta: listas para su uso en el entrenamiento inicial.

ID Fudo único, presente en todos los sistemas, permite cruzar información entre fuentes de forma consistente.



Por incorporar

Datos de contacto con soporte como features adicionales — el equipo aún debe definir el método de obtención.

ACCIÓN PENDIENTE · Definir fuente y método de extracción

Entrenamiento y despliegue



Al tratarse de un modelo pequeño, el diseño prioriza eficiencia y control de costos en cada etapa.

PASO 1

Entrenamiento local

Se entrena de forma local para reducir costos de cómputo, dado el tamaño acotado del modelo.



PASO 2

Hosting en producción

El modelo entrenado se hostea en Google Cloud Platform (GCP) para servir las predicciones en producción.

Generación de predicciones



Cadencia batch mensual

5

días

Las predicciones se generan en lote al cierre de cada mes, dentro de los 5 días posteriores, y quedan almacenadas para su rápido acceso por el equipo de CX.



Explicabilidad para el usuario

Cada predicción se acompaña de un mapa de calor con las features más importantes del modelo, mostrando cómo performó una cuenta particular sobre esas variables.

Esto permite que el equipo de CX entienda el "por qué" detrás de cada categoría asignada, no solo el resultado.

Crterios de xito

UMBRAL MÍNIMO

20%

de PR-AUC (a priori), definido junto con negocio como condici3n para salir a producci3n. Implica un 5X en mejora sobre la base actual



Mtrica de evaluaci3n

PR-AUC (Area bajo las curvas de PR y RC)

Se evalúa que tan bien el modelo distingue los casos positivos del resto de las cuentas, es una mezcla entre PR que marca de las predichas como Riesgo cuantas efectivamente los fueron y RC de todas las cuentas que se fueron cuantas atrapamos con la simulacion

Criterio de decisi3n

Validaci3n conjunta con negocio

El umbral de performance m3nima para pasar a producci3n no se define de forma unilateral por el equipo t3cnico, sino en conjunto con el área de negocio.

Seguimiento en producción

Una vez en producción, el modelo se monitorea de forma continua a través de dos frentes complementarios.



Control de No-Churn

Se compara el grupo de "No-Churn" observado contra las cuentas que fueron targeteadas por el modelo, verificando que las predicciones se sostengan en el tiempo.



Revenue perdido

Se mide el revenue perdido por abandono, conectando el desempeño del modelo directamente con el impacto económico del churn en el negocio.

GRACIAS